

Clasificación de la cobertura terrestre en ambientes salares

Análisis y visualización

Ambientes Salares

Python + Jupyter o Colab


Machine Learning

Ing. Pablo Nicolás Ramos
Mentoría M10 - Julio 2026

Quién soy

Perfil

- ▶ Ingeniero en Informática.
- ▶ Diplomado en Ciencia de Datos.
- ▶ Doctorando en Ingeniería.
- ▶ Docente en bases de datos, IA, cibercrimen y evidencia digital.
- ▶ Trabajo con Python, ciencia de datos, ML, automatización y sistemas de información.



De la imagen de un salar a una tabla

Cómo empezar a analizar datos ambientales con Python



Idea clave

Ustedes comienzan en el tercer bloque: **el dataset tabulado ya está conformado**. La tarea es comprenderlo, visualizarlo, curarlo y modelarlo.

La consigna científica

Problema general

Clasificar coberturas terrestres en ambientes salares a partir de variables tabulares derivadas de información satelital y polígonos de referencia.

Obligatorio

- ▶ Leer CSV con pandas.
- ▶ Explorar variables y clases.
- ▶ Visualizar patrones.
- ▶ Curar datos con criterio.
- ▶ Entrenar modelos clásicos de ML.
- ▶ Comunicar resultados.

Opcional

- ▶ Descargar Sentinel-2.
- ▶ Procesar raster.
- ▶ Reproyectar imágenes.
- ▶ Ejecutar GDAL o Rasterio.
- ▶ Extraer píxeles desde GeoJSON.
- ▶ Reconstruir el mosaico satelital.

Repositorio de trabajo

Repositorio

https://github.com/pablonicolasr/mentodatos_pdis

Carpeta operativa para la mentoría:

tables/

mentodatos_pdis/

tables/ <- **acá trabajan**

apuntes/

labels/

raster/

scripts/

Los cinco datasets tabulados

Archivo	Rol metodológico
olaroz_samples_pixels_raw.csv	Tabla inicial, cercana al resultado bruto de extracción.
olaroz_samples_pixels.csv	Tabla con controles y filtros iniciales.
olaroz_samples_features.csv	Dataset enriquecido. Punto de partida recomendado para el Práctico 1 y 2.
olaroz_samples_clean.csv	Versión de referencia luego de limpieza. Sirve para comparar criterios.
olaroz_samples_balanced.csv	Versión para analizar balance de clases y comparar modelado.

Regla de trabajo

Nunca sobrescribir los CSV originales. Cada grupo debe generar sus propios archivos derivados en una carpeta de trabajo.


Qué representa una fila

Unidad de análisis

Una fila representa una observación asociada a un píxel proveniente de un polígono de referencia.

- ▶ El `sample_id` agrupa observaciones del mismo polígono.
- ▶ Las bandas e índices describen la respuesta espectral.
- ▶ Las etiquetas describen la clase conocida.

Polígono: `sample_id = 17`



muchos píxeles, misma muestra



BO
BO
NI
c3


Familias de variables

Identificación	Índices	Etiquetas
<code>sample_id</code> Trazabilidad del polígono.	NDVI, NDWI, MNDWI, BSI Relaciones entre bandas.	<code>class_id</code> , <code>class_name</code> Variable objetivo.
Bandas	Coordenadas	Metadatos
B02, B03, B04, B08... Respuesta espectral.	Columnas espaciales disponibles. Sirven para explorar patrones.	<code>confidence</code> , <code>split</code> , <code>season</code> , <code>source</code> Contexto y trazabilidad.

Pregunta científica inicial

¿Qué variables separan mejor las coberturas y cuáles podrían introducir ruido o sesgo?

Bandas e índices: leer el lenguaje espectral



**No memorizamos números.
Interpretamos patrones.**

- ▶ Las bandas son mediciones originales.
- ▶ Los índices condensan relaciones útiles.
- ▶ Las clases pueden superponerse.
- ▶ Visualizar ayuda a formular hipótesis.


NDVI

NDWI

MNDWI

BSI

Cronograma de la mentoría



Foco de esta presentación

Preparar el camino para el **Práctico 1**: entender el dataset y producir análisis visuales defendibles.


Práctico 1: análisis y visualización

Objetivo

Comprender el dataset antes de intentar curarlo o modelarlo.

Preguntas guía

- ▶ ¿Qué representa cada fila?
- ▶ ¿Cuántas variables hay y qué función cumplen?
- ▶ ¿Cómo se distribuyen las clases?
- ▶ ¿Qué variables parecen informativas?
- ▶ ¿Hay señales de ruido, sesgo o desbalance?



Visualización: no es decorar, es argumentar

Gráficos mínimos

- ▶ Barras por clase.
- ▶ Histogramas de bandas e índices.
- ▶ Boxplots por clase.
- ▶ Matriz de correlación.
- ▶ Scatterplots entre índices.
- ▶ Mapa de puntos con coordenadas.

Regla de oro

Cada gráfico debe responder una pregunta. Si no responde ninguna pregunta, sobra.

- ✓ Título interpretativo
- ✓ Ejes claros
- ✓ Leyenda útil

- ✗ Gráfico sin pregunta
- ✗ Colores confusos
- ✗ Ejes sin nombre
- ✗ Conclusión ausente

Primera celda del notebook

```
from pathlib import Path
import random
import warnings

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px

warnings.filterwarnings("ignore")
RANDOM_STATE = 42
random.seed(RANDOM_STATE)
np.random.seed(RANDOM_STATE)

DATA_DIR = Path("tables")
DATASET = DATA_DIR / "olaroz_samples_features.csv"

df = pd.read_csv(DATASET)
print("Dimensiones:", df.shape)
display(df.head())
```

Meta: notebook reproducible, sin rutas absolutas y con el dataset cargado desde la carpeta del repositorio.

Primera inspección: mirar antes de modelar

```
print(df.shape)
display(df.head())
display(df.info())

display(
    df.describe(include="all").T
)
```


Qué buscamos

- ▶ Cantidad de filas y columnas.
- ▶ Tipos de datos.
- ▶ Nulos aparentes.
- ▶ Variables categóricas y numéricas.
- ▶ Columnas que son etiquetas o metadatos.

Antes de entrenar

Primero hay que entender la tabla. El ML sin diagnóstico previo es una caja negra con resultados frágiles.

Distribución de clases



Lectura científica

- ▶ El desbalance cambia la evaluación.
- ▶ Una clase pequeña puede quedar mal aprendida.
- ▶ La exactitud global puede engañar.


Métricas futuras

En modelado conviene mirar F1-macro, balanced accuracy y desempeño por clase.

Relaciones entre variables

Preguntas

- ▶ ¿NDVI y NDWI separan clases?
- ▶ ¿MNDWI mejora la detección de humedad?
- ▶ ¿BSI distingue suelo desnudo y salina?
- ▶ ¿Hay variables redundantes?



El peligro invisible: fuga por sample_id

Problema

Si píxeles del mismo polígono caen en entrenamiento y prueba, el modelo puede parecer mejor de lo que realmente es.

- ▶ Observaciones del mismo origen son parecidas.
- ▶ Una división fila por fila puede inflar resultados.
- ▶ El test deja de ser verdaderamente independiente.

División aleatoria fila por fila

✗ píxeles del mismo sample_id mezclados

División agrupada por sample_id

✓ polígonos completos separados

Qué debe entregar cada grupo el 07/08

Producto principal

Un notebook ejecutable de análisis y visualización.

- ▶ Carga del dataset.
- ▶ Descripción de variables.
- ▶ Estadística descriptiva.
- ▶ Gráficos interpretados.
- ▶ Conclusiones iniciales.

Criterio de evaluación

No se evalúa solo que el gráfico exista, sino que el equipo pueda explicar qué muestra y por qué importa.

- ▶ Claridad.
- ▶ Orden.
- ▶ Reproducibilidad.
- ▶ Interpretación.
- ▶ Preguntas para la etapa de curación.

Estructura sugerida del notebook 1

Sección	Contenido esperado
1. Contexto	Problema, dataset utilizado y objetivo del análisis.
2. Carga	Lectura de CSV, dimensiones, columnas y tipos.
3. Diccionario	Agrupación de variables por función.
4. Clases	Conteos, proporciones y comentarios sobre balance.
5. Variables	Distribuciones, boxplots y estadística descriptiva.
6. Relaciones	Correlaciones, scatterplots y comparaciones por clase.
7. Espacialidad	Visualización simple con coordenadas disponibles.
8. Cierre	Hallazgos, dudas y próximos pasos hacia curación.

Errores que quiero que eviten desde el inicio

Errores técnicos

- ▶ Usar rutas absolutas.
- ▶ No fijar semilla.
- ▶ No revisar tipos de datos.
- ▶ Mezclar etiquetas con predictores.
- ▶ Ignorar `sample_id`.

Errores comunicacionales

- ▶ Gráficos sin interpretación.
- ▶ Conclusiones sin evidencia.
- ▶ Exceso de capturas de pantalla.
- ▶ No explicar limitaciones.
- ▶ Confundir visualización con decoración.

Primer desafío para la clase

En equipos

Abran el dataset `olaroz_samples_features.csv` y produzcan tres respuestas iniciales:

1. ¿Cuál es la estructura del dataset?
2. ¿Qué clases aparecen y cómo se distribuyen?
3. ¿Qué dos variables parecen más interesantes para visualizar por clase?

Regla

Cada respuesta debe estar acompañada por una tabla o un gráfico. La afirmación debe salir de los datos.

El camino empieza así



Comprender los datos. Curar con criterio. Modelar con rigor. Comunicar con claridad.