

De datos extraídos a variables listas para analizar

Comparación científica de tres datasets tabulados

SalarIA

Python + Jupyter

EDA + Visualización

Pablo Nicolás Ramos
Mentoría M10 - Julio 2026

Objetivo de esta presentación

Qué vamos a comprender

- ▶ Cómo se relacionan `pixels_raw`, `pixels` y `features`.
- ▶ Qué cambia en filas, columnas, `sample_id` y clases.
- ▶ Por qué `features.csv` es el mejor punto de partida para análisis visual.
- ▶ Qué advertencias metodológicas deben tener desde el inicio.

Mensaje central

No son tres problemas distintos. Son tres momentos del mismo flujo de datos.

La idea fundamental



Primero cambia la población observada; después cambia la representación matemática.

Idea clave

De pixels_raw a pixels cambia la **población observada**. De pixels a features cambia la **representación matemática** de esa población.



Comparación general de los tres archivos

Dataset	Filas	Columnas	sample_id	Clases	Rol didáctico
pixels_raw.csv	21.507	22	70	4	Trazabilidad y auditoría
pixels.csv	13.878	22	50	3	Bandas originales filtradas
features.csv	13.878	31	50	3	EDA multivariado y ML

Lectura científica

Entre RAW y PIXELS se eliminan 7.629 filas y 20 sample_id. Entre PIXELS y FEATURES no se eliminan observaciones: se agregan nueve variables derivadas.

Qué cambia: filas, columnas y unidades de muestreo



Interpretación

La reducción ocurre antes de FEATURES. FEATURES no tiene más observaciones: tiene más variables para describir las mismas observaciones de PIXELS.

Dataset 1: olaroz_samples_pixels_raw.csv

Qué representa

Es la fotografía más cercana al resultado inicial de extracción de píxeles. Su valor principal es la trazabilidad.

- ▶ 21.507 filas.
- ▶ 22 columnas.
- ▶ 70 sample_id.
- ▶ 4 clases.

Uso ideal

Auditar qué existía antes del filtrado: filas, clases, unidades de muestreo y composición original.

Cautela

No debe usarse directamente para modelar sin justificar los criterios de filtrado.

Dataset 2: olaroz_samples_pixels.csv

Qué representa

Es la tabla de píxeles después de una etapa de selección o filtrado. Mantiene las 22 columnas base.

- ▶ 13.878 filas.
- ▶ 22 columnas.
- ▶ 50 sample_id.
- ▶ 3 clases.


Cambio visible

La clase salina desaparece.
agua_humedad pierde 54 filas.
suelo_rocoso y suelo_desnudo
conservan sus conteos.

Cautela

La comparación dice *qué* cambió,
no necesariamente *por qué*
cambió.

Distribución de clases: la pregunta cambia



Lectura didáctica

No asumir fenómeno ambiental: primero auditar los criterios de filtrado.

Dataset 3: `olaroz_samples_features.csv`

Qué representa

Es la misma población de `pixels.csv`, pero enriquecida con ingeniería de características.

- ▶ 13.878 filas.
- ▶ 31 columnas.
- ▶ 50 `sample_id`.
- ▶ 3 clases.
- ▶ 9 variables derivadas nuevas.

Rol recomendado

Punto de partida para:

- ▶ análisis visual;
- ▶ EDA multivariado;
- ▶ curación;
- ▶ aprendizaje automático.

Las nueve variables derivadas

Variable	Interpretación orientativa
NDVI	Contraste NIR-rojo; suele asociarse a vegetación.
NDWI	Contraste verde-NIR; ayuda a explorar agua y humedad.
MNDWI	Contraste verde-SWIR; variante orientada a agua/humedad.
NDBI_like	Relación inspirada en contrastes NIR-SWIR.
SWIR_ratio	Razón entre bandas SWIR.
NIR_SWIR_ratio	Relación entre infrarrojo cercano y SWIR.
RED_SWIR_ratio	Relación entre rojo y SWIR.
GREEN_SWIR_ratio	Relación entre verde y SWIR.
BLUE_RED_ratio	Relación entre azul y rojo.

Qué es una variable derivada

No agrega una nueva medición

Una feature derivada reorganiza información ya contenida en las bandas originales. Puede hacer más visible un patrón, pero no crea nuevos píxeles.

Riesgo

Las razones e índices pueden introducir:

- ▶ redundancia;
- ▶ valores extremos;
- ▶ inestabilidad;
- ▶ sobreinterpretación.


Idea clave

Más columnas no significa automáticamente mejor dataset. Significa más formas de mirar la misma población de observaciones.

Las 22 columnas base compartidas

Familia	Columnas	Función
Identificación	sample_id	Trazabilidad del polígono.
Etiquetas	class_id, class_name, macro_class	Objetivo conocido.
Metadatos	season, confidence, split, source, notes	Contexto.
Escena y posición	scl, x, y	Calidad y ubicación.
Bandas	B02, B03, B04, B05, B06, B07, B08, B8A, B11, B12	Señal espectral.

Jerarquía de los datos



Idea metodológica

Dos filas con el mismo `sample_id` suelen estar más relacionadas entre sí que dos filas elegidas al azar. Por eso, muchas filas no equivalen necesariamente a muchas muestras independientes.

Comparación conceptual

Aspecto	pixels_raw	pixels	features
Población de filas	Mayor y más diversa	Reducida por selección	Igual a pixels
Estructura	22 columnas base	22 columnas base	22 base + 9 derivadas
sample_id	70	50	50
Clases	4	3	3
Clase salina	Presente	Ausente	Ausente
Objetivo	Trazabilidad y auditoría	Bandas filtradas	Análisis y ML
Riesgo	Modelar sin justificar filtros	Olvidar pérdida de clases	Sobreinterpretar features

Analogía didáctica: la biblioteca

RAW

Inventario inicial de todos los libros encontrados.

PIXELS

Catálogo luego de retirar libros que no cumplen las reglas.

FEATURES

Mismo catálogo filtrado, pero con nuevas columnas calculadas.

Dos confusiones que evitamos

- ▶ Agregar features no aumenta el tamaño muestral.
- ▶ Filtrar filas puede cambiar la pregunta científica.

Cuál usar para cada actividad

Objetivo	Dataset recomendado
Comprender linaje de datos	<code>pixels_raw + pixels</code>
Analizar bandas originales	<code>pixels</code>
Práctico 1: análisis y visualización	<code>features</code>
Práctico 2: curación	<code>features</code> , con RAW/PIXELS como referencia
Comparar ingeniería de variables	<code>pixels vs features</code>
Machine Learning	<code>features</code> curado, respetando <code>sample_id</code>

Recomendación para mañana

Comenzar el análisis visual con `features.csv`, pero dedicar una sección breve a comparar dimensiones y clases de los tres archivos.

Secuencia de análisis recomendada

1. Cargar los tres archivos.
2. Comparar dimensiones: filas, columnas, memoria.
3. Comparar columnas comunes y columnas nuevas.
4. Comparar `sample_id`.
5. Comparar distribución de clases.
6. Verificar que `pixels` y `features` tengan las mismas observaciones.
7. Explorar nulos, infinitos, outliers y correlaciones de features.
8. Separar hechos observados de explicaciones aún no verificadas.

Criterio científico

Una comparación sólida no termina en conteos: explica cómo cada transformación modifica la población, la representación y los riesgos metodológicos.

Código mínimo para reproducir la comparación

```
from pathlib import Path
import pandas as pd

DATA_DIR = Path("tables")
archivos = {
    "raw": DATA_DIR / "olaroz_samples_pixels_raw.csv",
    "pixels": DATA_DIR / "olaroz_samples_pixels.csv",
    "features": DATA_DIR / "olaroz_samples_features.csv",
}

tablas = {nombre: pd.read_csv(ruta) for nombre, ruta in archivos.items()}

resumen = []
for nombre, df in tablas.items():
    resumen.append({
        "dataset": nombre,
        "filas": len(df),
        "columnas": df.shape[1],
        "sample_id": df["sample_id"].nunique(),
        "clases": df["class_name"].nunique(),
        "nulos": int(df.isna().sum().sum()),
    })
```

Verificación clave: PIXELS vs FEATURES

```
base = ["sample_id", "x", "y", "class_name"]

claves_pixels = set(map(tuple, tablas["pixels"][base].to_numpy()))
claves_features = set(map(tuple, tablas["features"][base].to_numpy()))

print("Mismas observaciones:", claves_pixels == claves_features)
print("Solo en pixels:", len(claves_pixels - claves_features))
print("Solo en features:", len(claves_features - claves_pixels))

columnas_nuevas = sorted(
    set(tablas["features"].columns) - set(tablas["pixels"].columns)
)
print("Features agregadas:", columnas_nuevas)
```

Preguntas científicas para los estudiantes

Linaje y calidad

- ▶ ¿Qué filas y `sample_id` desaparecen?
- ▶ ¿Qué clases cambian entre versiones?
- ▶ ¿Hay nulos, infinitos o duplicados?
- ▶ ¿Qué variable parece problemática?

Representación y análisis

- ▶ ¿Las features separan clases?
- ▶ ¿Hay variables redundantes?
- ▶ ¿Las clases están espacialmente concentradas?
- ▶ ¿Cuántos píxeles aporta cada `sample_id`?

Errores frecuentes que deben evitar

Errores técnicos

- ▶ Decir que FEATURES tiene más datos porque tiene más columnas.
- ▶ Entrenar con RAW y PIXELS como si fueran muestras independientes.
- ▶ Usar `class_name` como predictor.
- ▶ Ignorar `sample_id`.

Errores interpretativos

- ▶ Interpretar la desaparición de salina sin auditar filtros.
- ▶ Asumir que todo índice derivado será útil.
- ▶ Eliminar valores extremos sin revisar si son reales.
- ▶ Confundir visualización con decoración.

Actividad introductoria sugerida

En equipos

Abran los tres CSV y construyan una comparación mínima defendible.

1. Tabla resumen: filas, columnas, `sample_id`, clases, nulos.
2. Gráfico de filas por dataset.
3. Gráfico de distribución de clases.
4. Lista de columnas nuevas de `features.csv`.
5. Tres conclusiones: una sobre población, una sobre representación y una sobre riesgos.

Regla

Cada afirmación debe salir de una tabla, un conteo o un gráfico reproducible.

La lectura correcta del flujo



Primero se redefine la población. Después se amplía la representación.

Idea clave

Para el Práctico 1, `features.csv` es el punto de entrada. Compararlo con RAW y PIXELS evita trabajar con una caja negra.

Comprender los datos

antes de curar, modelar y comunicar

Trazabilidad

Criterio

Evidencia