
Análisis y Visualización de Datos

M10

Salar de Olaroz - dataset tabular raw

Etapla consultiva previa al Aprendizaje Supervisado

Python + Pandas + Visualización científica + criterio de sample_id

Propósito de esta etapa

Idea central

Esta no es una etapa para entrenar modelos. Es una etapa para comprender el dataset, detectar riesgos metodológicos y construir visualizaciones que produzcan evidencia.

Preguntas guía

- ¿Qué representa una fila?
- ¿Cómo se distribuyen las clases?
- ¿Cuánto pesa cada `sample_id`?
- ¿El split es balanceado por píxeles y por muestras?
- ¿Qué aporta el `sc1` como control?

Lo que se evita ahora

- Entrenar modelos sin diagnóstico.
- Mezclar píxeles de un mismo polígono.
- Confundir cantidad de píxeles con muestras independientes.
- Usar `sc1` como etiqueta final.


Fotografía ejecutiva del dataset

Indicador	Valor
Filas	21.507
Columnas	22
sample_id únicos	70
Clases	4
Nulos totales	0
Duplicados exactos	0
Duplicados por coordenada	0
Bandas Sentinel-2 en tabla	10

Lectura consultiva

La calidad estructural inicial es buena. El riesgo principal no está en nulos o duplicados, sino en la dependencia entre filas que comparten el mismo `sample_id`.


Píxeles vs muestras: dos distribuciones distintas



Mensaje

Por píxeles, las clases no pesan igual. Por `sample_id`, agua, salina y suelo desnudo tienen 20 muestras cada una, mientras suelo rocoso tiene 10. Esto cambia la lectura estadística.



El sample_id no es un detalle administrativo



Riesgo

El tamaño de las muestras varía entre 24 y 928 píxeles. Un sample grande puede dominar métricas y gráficos si se trabaja fila por fila sin control.


Split: revisar por píxeles y por muestras



Lectura

Por `sample_id`, el split es cercano a 70/15/15. Por píxeles, train sube a más del 80 % porque algunos polígonos de entrenamiento tienen más píxeles.

SCL: útil para control, peligroso como etiqueta




Interpretación

La salina aparece como SCL 11 y suelo/rocoso como SCL 5. Esto sirve para auditar coherencia, pero no reemplaza la etiqueta de cobertura terrestre.

Distribución espacial: mirar el territorio


Distribución espacial de observaciones



Buena práctica

Un dataset satelital tabulado conserva dependencia espacial. Antes de modelar, conviene analizar si las clases y los splits están espacialmente concentrados.


Centroides por sample_id: control de splits espaciales



Pregunta hacia adelante

¿Los conjuntos train, validation y test representan zonas comparables o están espacialmente sesgados?

Perfiles espectrales medianos por clase




Lectura

Las bandas muestran diferencias entre clases. La visualización del perfil mediano ayuda a formular hipótesis sobre separabilidad antes de calcular modelos.

Índices exploratorios calculados desde la tabla raw


Índices calculados desde la tabla raw: separabilidad exploratoria



Criterio

No se entrena todavía. Se calculan índices solo para observar contrastes y generar preguntas para la etapa de features y curación.

Redundancia potencial entre variables



Lectura

La correlación no decide por sí sola qué eliminar. Sirve para detectar redundancia potencial y orientar la curación posterior.

Variables: qué mirar y qué no usar como predictor

Variables predictoras candidatas

- Bandas: B02...B12
- Índices derivados en una etapa posterior
- Coordenadas: solo con análisis crítico

No usar directamente como predictores

- sample_id
- class_id, class_name, macro_class
- split
- notes, source, confidence, season
- scl: usar con cuidado como control, no como verdad final

Nunca dividir al azar fila por fila sin considerar `sample_id`

Si píxeles del mismo polígono quedan en entrenamiento y prueba, el modelo puede parecer más preciso de lo que realmente es.

```
from sklearn.model_selection import GroupShuffleSplit

groups = df["sample_id"]
splitter = GroupShuffleSplit(
    n_splits=1,
    test_size=0.20,
    random_state=42
)
train_idx, test_idx = next(splitter.split(X, y, groups=groups))
```

Idea: separar polígonos completos, no píxeles sueltos.

Hallazgos que sí podemos afirmar ahora

- ➊ La tabla raw tiene estructura limpia: sin nulos ni duplicados exactos.
- ➋ La distribución por píxeles y por `sample_id` cuenta historias diferentes.
- ➌ El tamaño de los polígonos es desigual y puede sesgar análisis fila por fila.
- ➍ El SCL confirma patrones útiles, pero no reemplaza la clasificación temática.
- ➎ El análisis espacial es obligatorio antes de evaluar modelos.
- ➏ Las bandas muestran señales de separabilidad, pero falta curación y validación.

Preguntas abiertas para que exploren los estudiantes

- ¿Qué pasa si se analiza por píxel versus por `sample_id` agregado?
- ¿Qué variables separan mejor salina de suelo desnudo?
- ¿Hay zonas espaciales subrepresentadas en test?
- ¿Conviene excluir o auditar píxeles con SCL no esperado?
- ¿Qué cambia al pasar de `pixels_raw` a `features`?
- ¿Qué visualizaciones permiten explicar mejor la incertidumbre?

Cierre

El objetivo del primer práctico no es agotar el análisis, sino construir una base correcta para curar datos y modelar con rigor.

Datos → Visualización → Criterio

Antes de modelar, el equipo debe poder defender qué representa cada fila, cada clase y cada `sample_id`.