

Mentoría M10

Práctico 2: EDA, Curación de Datos e Ingeniería ETL

SalarIA - Cobertura terrestre en ambientes salares

Entrega 04/09

Objetivo del Práctico 2

Pasar de **analizar y visualizar** a **curar, documentar y preparar** los datos para aprendizaje automático.

Resultado esperado

Un dataset depurado, trazable, auditable y reproducible.

Qué se hizo bien en el Práctico 1

- ▶ Comparación de etapas: `pixels_raw` -> `pixels` -> `features`.
- ▶ Histogramas, boxplots, correlaciones y firmas espectrales.
- ▶ Análisis de clases por píxel y por polígono.
- ▶ Atención al filtro SCL y a la estructura espacial.
- ▶ Primeras hipótesis sobre separabilidad de clases.

Qué faltaba para una curación profesional

- ▶ ETL reproducible.
- ▶ Contrato de datos.
- ▶ Bitácora de decisiones.
- ▶ Métodos estadísticos formales.
- ▶ Control de fuga por `sample_id`.
- ▶ Dataset final versionado.

Pipeline ETL propuesto

CSV originales

⇓ Extract

SQLite staging

⇓ Transform + Quality

Curated mart

⇓ Load

CSV / Parquet / Reporte

Por qué SQLite + SQLAlchemy

- ▶ Portable: un solo archivo `.sqlite`.
- ▶ Reproducible: tablas de entrada, salida y métricas.
- ▶ Auditable: cada decisión queda registrada.
- ▶ Simple: no requiere servidor.
- ▶ Profesional: acerca la mentoría a ingeniería de datos real.

Carga a staging

```
from sqlalchemy import create_engine
engine = create_engine("sqlite:///data/warehouse/m10_etl.sqlite")

df.to_sql("stg_olaroz_samples_features", engine,
          if_exists="replace", index=False)
```

Debe responder

- ▶ ¿Qué columnas son obligatorias?
- ▶ ¿Qué tipos se esperan?
- ▶ ¿Qué dominios son válidos?
- ▶ ¿Qué rangos son plausibles?
- ▶ ¿Qué relaciones deben cumplirse?

Familias de variables

Grupo	Ejemplos
Identificación	<code>sample_id</code>
Etiquetas	<code>class_id</code> , <code>class_name</code>
Metadatos	<code>split</code> , <code>source</code> , <code>season</code>
Bandas	<code>B02</code> , <code>B03</code> , <code>B08</code> , <code>B11</code>
Índices	<code>NDVI</code> , <code>NDWI</code> , <code>MNDWI</code> , <code>BSI</code>
Espaciales	<code>x</code> , <code>y</code> , <code>scl</code>

Controles mínimos

- ▶ Nulos e infinitos.
- ▶ Duplicados exactos y semánticos.
- ▶ Tipos incorrectos.
- ▶ Categorías inconsistentes.
- ▶ Variables constantes o casi constantes.
- ▶ Rangos improbables.
- ▶ Valores extremos.
- ▶ Correlación excesiva.
- ▶ Desbalance por píxel y por polígono.

Preguntas clave

- ▶ ¿Cuánto falta?
- ▶ ¿Dónde falta?
- ▶ ¿Falta por clase o por split?
- ▶ ¿Conviene imputar, descartar o marcar?

Outliers: no borrar automáticamente

En ambientes salares, un extremo puede ser una señal real.

- ▶ Agua: reflectancia baja en NIR/SWIR.
- ▶ Sal: respuestas altas o particulares.
- ▶ Roca: variabilidad mineralógica.
- ▶ Bordes: mezcla de coberturas.

Método	Uso
IQR	Diagnóstico robusto simple
Z-score	Extremos bajo hipótesis aproximadamente normal
MAD	Alternativa robusta ante asimetría
Isolation Forest	Rarezas multivariadas

Redundancia

- ▶ Muchas bandas cercanas están altamente correlacionadas.
- ▶ Algunos índices duplican información de bandas.
- ▶ Correlación alta no implica borrar automáticamente.
- ▶ Decisión: conservar, transformar o seleccionar.

$$|\rho| > 0,95 \Rightarrow \text{revisar}$$

- ▶ ANOVA: diferencias de medias.
- ▶ Kruskal-Wallis: diferencias no paramétricas.
- ▶ Eta cuadrado: tamaño del efecto.
- ▶ Información mutua: dependencia no lineal.
- ▶ Boxplots e histogramas: interpretación visual.

No alcanza con contar píxeles.

Por píxel

Influye en el entrenamiento.

Por polígono

Influye en diversidad real y generalización.

Riesgo

Si píxeles del mismo `sample_id` caen en train y test, el modelo puede memorizar el polígono.

Solución: split agrupado por `sample_id`.

Split agrupado

```
from sklearn.model_selection import GroupShuffleSplit

splitter = GroupShuffleSplit(test_size=0.2, random_state=42)
train_idx, test_idx = next(splitter.split(X, y, groups=df["sample_id"]))
```

- ▶ Coordenadas centradas.
- ▶ Distancia al centroide global.
- ▶ Ángulo respecto del centroide.
- ▶ Distancia al centroide del polígono.
- ▶ Si hay geometrías: área, perímetro y compacidad.

Variables con riesgo de fuga

Variable	Motivo
class_id	Etiqueta
class_name	Etiqueta
macro_class	Derivada de etiqueta
sample_id	Identificador de grupo
split	Partición
source	Metadato

Problema	Evidencia	Decisión	Justificación
Nulos	n	imputar/no	criterio
Duplicados	n	eliminar	sesgo
Outliers	n	marcar	dominio
Correlación	pares	revisar	redundancia
Fuga	sample	split grupo	evaluación

Curated CSV



Imputación



Escalado



Selección de variables



Modelo supervisado / no supervisado

Preprocesamiento reproducible

```
preprocess = ColumnTransformer([
    ("num", Pipeline([
        ("imputer", SimpleImputer(strategy="median")),
        ("scaler", StandardScaler())
    ]), numeric_features)
])
```

Entregables del Práctico 2

- ▶ Notebook ejecutable de punta a punta.
- ▶ CSV curado con nombre nuevo.
- ▶ SQLite con staging, quality y mart final.
- ▶ Decision log.
- ▶ Reporte técnico breve.
- ▶ Conclusiones defendibles.

Criterios de una gran entrega

1. Reproducibilidad.
2. Evidencia estadística.
3. Interpretación ambiental.
4. Prevención de fuga.
5. Curación documentada.
6. Preparación para ML.

Curar datos no es limpiar por limpiar.

Es construir una base confiable para que el modelo aprenda cobertura terrestre y no artefactos del dataset.