

MENTORÍA EN CIENCIA DE DATOS

M10

Clasificación de la cobertura terrestre en ambientes salares

Guía introductoria para el análisis
del dataset tabular

Los equipos trabajarán directamente con los archivos CSV ya conformados. El objetivo no es procesar imágenes satelitales, sino comprender, explorar, curar, visualizar y modelar los datos derivados de ellas.

Caso de estudio: Salar de Olaroz, Jujuy, Argentina

Mentor: **Pablo Nicolás Ramos**

Julio de 2026

Repositorio de referencia:

https://github.com/pablonicolasr/mentodatos_pdis

Índice

1. Propósito y alcance	1
1.1. Objetivos de aprendizaje	1
2. Contexto del problema	1
2.1. Cobertura terrestre en ambientes salares	1
2.2. Qué significa trabajar con datos satelitales ya tabulados	2
3. Origen del dataset y función de los GeoJSON	2
4. Archivos disponibles en tables	2
4.1. Clases presentes en las tablas	3
4.2. Cuál archivo usar	3
5. Unidad de análisis y jerarquía de observaciones	4
5.1. Fila, píxel y polígono	4
5.2. Implicancias estadísticas	4
6. Diccionario de variables	4
6.1. Identificación, etiquetas y metadatos	4
6.2. Bandas espectrales	5
6.3. Índices y razones derivadas	5
7. Primer acceso al dataset con Python	6
7.1. Entorno sugerido	6
7.2. Lectura e inspección inicial	6
7.3. Verificación mínima de estructura	6
7.4. Validación de pertenencia por grupo	6
8. Práctico 1: análisis y visualización	7
8.1. Preguntas orientadoras	7
8.2. Visualizaciones mínimas sugeridas	7
9. Práctico 2: análisis exploratorio y curación	8
9.1. Comparación entre etapas del dataset	8
9.2. Aspectos que deben revisarse	8
9.3. Variables que no deben usarse directamente como predictores	9
9.4. Tratamiento de valores atípicos	9

10.Práctico 3: aprendizaje automático	9
10.1. Alternativa A: aprendizaje supervisado	10
10.2. Métricas recomendadas	10
10.3. Alternativa B: aprendizaje no supervisado	11
10.4. Alternativa C: enfoque combinado	11
11.Prevencción de fuga de información	12
11.1. Riesgos específicos de esta mentoría	12
11.2. Uso correcto de los splits	12
12.Reproducibilidad y organización del trabajo	12
12.1. Estructura recomendada	12
12.2. Buenas prácticas	13
13.Cronograma de la mentoría	13
14.Video final y presentación en jornadas	14
14.1. Contenido recomendado para el video	14
14.2. Criterios de comunicación	14
15.Checklist general	14
16.Glosario breve	15
17.Recursos	15

1 Propósito y alcance

La mentoría **M10: Clasificación de la cobertura terrestre en ambientes salares** propone resolver un problema de ciencia de datos aplicado al estudio del territorio. A partir de observaciones derivadas de imágenes Sentinel-2, los equipos analizarán patrones asociados con diferentes coberturas terrestres del Salar de Olaroz.

El repositorio contiene un conjunto de tablas CSV preparadas previamente. Cada tabla representa una etapa distinta de conformación del dataset: extracción inicial, filtrado, generación de variables, curación y balanceo.

Qué harán y qué no harán los equipos

Sí harán: lectura de archivos CSV, comprensión de variables, análisis estadístico, visualización, detección de problemas de calidad, curación de datos, selección de atributos, aprendizaje supervisado, aprendizaje no supervisado y comunicación de resultados.

No harán: descarga de imágenes satelitales, corrección atmosférica, mosaicos, remuestreo de bandas, recorte de rasters, aplicación de máscaras o extracción de píxeles desde archivos GeoJSON.

1.1 Objetivos de aprendizaje

Al finalizar la mentoría, se espera que los equipos puedan:

- comprender qué representa cada fila, columna, etiqueta y agrupación del dataset;
- reconocer las etapas por las que pasó el dato antes de llegar a una tabla analítica;
- realizar análisis descriptivos y visualizaciones apropiadas;
- detectar desbalance, valores atípicos, redundancia, correlación y posibles fugas de información;
- justificar decisiones de curación y preparación de datos;
- entrenar y evaluar modelos supervisados y/o no supervisados;
- comunicar resultados técnicos de manera clara, reproducible y responsable.

2 Contexto del problema

2.1 Cobertura terrestre en ambientes salares

La cobertura terrestre describe los materiales y elementos presentes sobre la superficie: agua, humedad, sal, suelo desnudo, roca, vegetación, infraestructura u otras unidades. En un ambiente salar, varias coberturas pueden presentar transiciones graduales y respuestas espectrales similares.

El problema de clasificación puede expresarse como:

$$\hat{y} = f(x_1, x_2, \dots, x_p), \quad (1)$$

donde $x_1, \dots, x_p$ representan bandas espectrales e índices derivados, y $\hat{y}$ es la cobertura estimada por el modelo.

2.2 Qué significa trabajar con datos satelitales ya tabulados

Los valores que originalmente estaban distribuidos espacialmente en una imagen fueron convertidos en filas y columnas. El equipo recibe, por lo tanto, un dataset tabular convencional, pero debe conservar una interpretación geoespacial:

- una fila corresponde a un píxel muestreado;
- varios píxeles pueden provenir de un mismo polígono de referencia;
- `sample_id` identifica el polígono o unidad de muestreo de origen;
- `x` e `y` conservan la posición espacial del píxel;
- las bandas e índices son variables predictoras;
- `class_name` y `class_id` son etiquetas de cobertura.

La tabla no elimina la dimensión espacial

Aunque los datos se carguen con `pandas`, las observaciones cercanas o pertenecientes al mismo `sample_id` no son independientes. Esta dependencia debe considerarse al dividir los datos, validar modelos e interpretar métricas.

3 Origen del dataset y función de los GeoJSON

Los archivos GeoJSON fueron utilizados en una etapa previa para representar polígonos etiquetados sobre el área de estudio. Esos polígonos permitieron extraer los valores de los píxeles contenidos en cada región y construir las tablas disponibles en el repositorio.

Los equipos **no necesitan editar ni procesar los GeoJSON**. Sin embargo, deben comprender su función porque explica la estructura del dataset:

1. se delimita un polígono homogéneo sobre el territorio;
2. se asigna una etiqueta ambiental al polígono;
3. se extraen los píxeles comprendidos dentro de esa geometría;
4. cada píxel se convierte en una fila;
5. la etiqueta y los metadatos del polígono se repiten en todas sus filas;
6. el identificador `sample_id` permite reconstruir la pertenencia de cada píxel a su polígono original.

Consecuencia para el modelado

No se debe dividir aleatoriamente el dataset por filas sin controlar `sample_id`. Si píxeles del mismo polígono aparecen simultáneamente en entrenamiento y prueba, el resultado puede ser artificialmente optimista.

4 Archivos disponibles en tables

Los datos de trabajo se encuentran en:

https://github.com/pablonicolasr/mentodatos_pdis/tree/main/tables

La siguiente tabla resume el estado actual de los archivos del repositorio.

Archivo	Filas	Cols.	Interpretación
olaroz_samples_pixels_raw.csv	21.507	22	Tabla de píxeles inicial. Contiene 70 <code>sample_id</code> y cuatro clases: salina, agua/humedad, suelo desnudo y suelo rocoso.
olaroz_samples_pixels.csv	13.878	22	Tabla de píxeles posterior al filtrado aplicado durante la preparación. Contiene 50 <code>sample_id</code> y tres clases.
olaroz_samples_features.csv	13.878	31	Agrega índices y razones espectrales a las bandas originales. Es una tabla apropiada para comenzar el análisis multivariado.
olaroz_samples_clean.csv	13.878	31	Versión curada del conjunto con variables derivadas. Es una referencia para estudiar decisiones de limpieza y consistencia.
olaroz_samples_balanced.csv	8.025	31	Versión balanceada con 2.675 filas por clase. Es útil para comparar modelos sin predominio de la clase mayoritaria.

4.1 Clases presentes en las tablas

En la tabla cruda aparecen cuatro clases:

- `salina`: 7.575 filas;
- `agua_humedad`: 6.771 filas;
- `suelo_rocoso`: 4.432 filas;
- `suelo_desnudo`: 2.729 filas.

En las tablas `pixels`, `features` y `clean` se conservan tres clases:

- `agua_humedad`: 6.717 filas;
- `suelo_rocoso`: 4.432 filas;
- `suelo_desnudo`: 2.729 filas.

La tabla balanceada contiene exactamente 2.675 observaciones de cada una de esas tres clases.

4.2Cuál archivo usar

Recomendación inicial

Para el primer acercamiento puede utilizarse `olaroz_samples_features.csv`, porque reúne metadatos, bandas e índices. Para modelado comparativo conviene trabajar tanto con `olaroz_samples_clean.csv` como con `olaroz_samples_balanced.csv`. La tabla cruda debe conservarse como referencia y no sobrescribirse.

5 Unidad de análisis y jerarquía de observaciones

5.1 Fila, píxel y polígono

La unidad más pequeña de la tabla es el píxel. Sin embargo, el diseño del muestreo tiene una estructura jerárquica:

$$\text{píxeles} \subset \text{polígonos de referencia} \subset \text{clases de cobertura.} \quad (2)$$

En las tablas sin balancear existen 13.878 píxeles provenientes de 50 polígonos. El tamaño de cada grupo no es uniforme: algunos `sample_id` aportan muchas más filas que otros.

5.2 Implicancias estadísticas

- Un polígono grande puede tener más peso que uno pequeño si cada píxel se considera una observación independiente.
- Dos filas del mismo `sample_id` suelen ser más parecidas entre sí que dos filas elegidas al azar.
- La distribución por filas y la distribución por polígonos responden preguntas diferentes.
- Las métricas deben calcularse respetando los conjuntos `train`, `validation` y `test` ya provistos.
- También puede ser útil resumir resultados por `sample_id`, no solamente por píxel.

Comprobación básica

Verificar que cada `sample_id` pertenece a una sola clase y a un solo `split`. Luego comparar el número de píxeles por polígono mediante una tabla y un gráfico.

6 Diccionario de variables

6.1 Identificación, etiquetas y metadatos

Variable	Significado
<code>sample_id</code>	Identificador del polígono o unidad de muestreo de origen. Se repite para todos los píxeles extraídos del mismo polígono.
<code>class_id</code>	Código numérico de la clase objetivo.
<code>class_name</code>	Nombre de la clase: por ejemplo, <code>agua_humedad</code> , <code>suelo_desnudo</code> o <code>suelo_rocoso</code> .
<code>macro_class</code>	Agrupación conceptual de nivel superior, como <code>humedad_agua</code> o <code>sin_vegetacion</code> .
<code>season</code>	Estación o período de referencia. En el dataset actual aparece <code>seca</code> .
<code>confidence</code>	Nivel de confianza asignado durante el etiquetado. En el dataset actual aparece <code>alta</code> .
<code>split</code>	Conjunto reservado para entrenamiento, validación o prueba.
<code>source</code>	Fuente de datos. En el dataset actual: <code>sentinel2_12a_2025</code> .
<code>notes</code>	Descripción cualitativa del polígono de origen.

Variable	Significado
scl	Código de clasificación de escena asociado al píxel. Debe tratarse como variable categórica, aunque esté almacenado como entero.
x, y	Coordenadas espaciales del centro del píxel, expresadas en el sistema proyectado de trabajo.

6.2 Bandas espectrales

Las bandas representan la respuesta registrada por el sensor en diferentes regiones del espectro electromagnético.

Variable	Región aproximada	Utilidad interpretativa
B02	Azul	Respuesta visible; puede ser sensible a atmósfera, agua y superficies claras.
B03	Verde	Útil en análisis de agua, humedad y reflectancia visible.
B04	Rojo	Relacionada con absorción de vegetación y contraste de suelos.
B05, B06, B07	Borde rojo	Transición entre rojo e infrarrojo cercano.
B08, B8A	Infrarrojo cercano	Contraste entre vegetación, agua, humedad y suelo.
B11, B12	Infrarrojo de onda corta	Sensibles a humedad, minerales, suelo y superficies secas.

6.3 Índices y razones derivadas

Las tablas de 31 columnas incluyen las siguientes variables construidas:

- NDVI: índice normalizado asociado principalmente con vegetación;
- NDWI: índice de diferencia normalizada relacionado con agua/humedad;
- MNDWI: variante que utiliza una banda SWIR;
- NDBI_like: indicador inspirado en contrastes NIR–SWIR;
- SWIR_ratio: razón entre bandas del infrarrojo de onda corta;
- NIR_SWIR_ratio: relación entre infrarrojo cercano y SWIR;
- RED_SWIR_ratio: relación entre rojo y SWIR;
- GREEN_SWIR_ratio: relación entre verde y SWIR;
- BLUE_RED_ratio: relación entre azul y rojo.

No interpretar índices de manera automática

Un índice no “demuestra” por sí solo la presencia de una cobertura. Su interpretación depende del ambiente, el sensor, la época y la combinación con otras variables. En un salar, superficies claras, humedad y sales pueden producir comportamientos distintos a los observados en

ambientes urbanos o agrícolas.

7 Primer acceso al dataset con Python

7.1 Entorno sugerido

```
1 python -m venv .venv
2
3 # Windows / Cmder
4 .venv\Scripts\activate
5
6 pip install pandas numpy matplotlib scikit-learn jupyter
7 jupyter notebook
```

7.2 Lectura e inspección inicial

```
1 from pathlib import Path
2 import pandas as pd
3
4 DATA_DIR = Path("tables")
5 archivo = DATA_DIR / "olaroz_samples_features.csv"
6
7 df = pd.read_csv(archivo)
8
9 print(df.shape)
10 print(df.head())
11 print(df.info())
12 print(df.describe(include="all").T)
```

7.3 Verificación mínima de estructura

```
1 columnas_clave = {
2     "sample_id", "class_id", "class_name", "macro_class",
3     "split", "scl", "x", "y", "B02", "B03", "B04",
4     "B08", "B11", "B12"
5 }
6
7 faltantes = columnas_clave - set(df.columns)
8 if faltantes:
9     raise ValueError(f"Faltan columnas: {sorted(faltantes)}")
10
11 print("Filas:", len(df))
12 print("Polígonos:", df["sample_id"].nunique())
13 print("Clases:", df["class_name"].value_counts())
14 print("Splits:", df["split"].value_counts())
```

7.4 Validación de pertenencia por grupo

```
1 clases_por_grupo = df.groupby("sample_id")["class_name"].nunique()
2 splits_por_grupo = df.groupby("sample_id")["split"].nunique()
3
```

```
4 assert clases_por_grupo.max() == 1, "Un sample_id tiene varias clases"
5 assert splits_por_grupo.max() == 1, "Un sample_id aparece en varios splits"
```

8 Práctico 1: análisis y visualización

Fecha de entrega: 07/08/2026.

El primer práctico debe demostrar que el equipo comprende el dataset y puede comunicar sus principales características mediante estadísticas y gráficos.

8.1 Preguntas orientadoras

- ¿Cuántas filas, columnas, clases y polígonos existen?
- ¿Cuál es la distribución de clases por píxel y por `sample_id`?
- ¿Cómo se distribuyen las bandas y los índices?
- ¿Qué variables presentan escalas, asimetrías o dispersiones muy diferentes?
- ¿Qué relaciones se observan entre bandas, índices y clases?
- ¿La distribución espacial de las muestras es homogénea?
- ¿Los splits mantienen una representación razonable de las clases?

8.2 Visualizaciones mínimas sugeridas

1. gráfico de barras de clases por filas;
2. gráfico de barras de polígonos por clase;
3. histograma de variables seleccionadas;
4. boxplots por clase;
5. matriz de correlación de variables numéricas;
6. dispersión espacial usando `x` e `y`;
7. comparación de distribución entre `train`, `validation` y `test`.

```
1 import matplotlib.pyplot as plt
2
3 conteo = df["class_name"].value_counts().sort_index()
4 conteo.plot(kind="bar")
5 plt.title("Cantidad de píxeles por clase")
6 plt.xlabel("Clase")
7 plt.ylabel("Cantidad")
8 plt.tight_layout()
9 plt.show()
```

```
1 for clase, grupo in df.groupby("class_name"):
2     plt.scatter(grupo["x"], grupo["y"], s=5, alpha=0.45, label=clase)
3
4 plt.title("Distribución espacial de las muestras")
5 plt.xlabel("Coordenada x")
```

```
6 plt.ylabel("Coordenada y")
7 plt.legend()
8 plt.axis("equal")
9 plt.tight_layout()
10 plt.show()
```

Producto esperado del Práctico 1

Un notebook ejecutable con introducción, carga de datos, descripción de variables, análisis univariado y bivariado, visualizaciones comentadas, hallazgos principales y conclusiones iniciales. Cada gráfico debe responder una pregunta y estar acompañado por una interpretación.

9 Práctico 2: análisis exploratorio y curación

Fecha de entrega: 04/09/2026.

El segundo práctico debe profundizar el diagnóstico y construir una versión justificadamente curada del dataset. No se evalúa solamente que el código funcione, sino que las decisiones sean explícitas, reproducibles y defendibles.

9.1 Comparación entre etapas del dataset

Los equipos deberían comparar, al menos, las tablas `pixels_raw`, `pixels`, `features`, `clean` y `balanced`.

```
1 archivos = [
2     "olaroz_samples_pixels_raw.csv",
3     "olaroz_samples_pixels.csv",
4     "olaroz_samples_features.csv",
5     "olaroz_samples_clean.csv",
6     "olaroz_samples_balanced.csv",
7 ]
8
9 resumen = []
10 for nombre in archivos:
11     tabla = pd.read_csv(DATA_DIR / nombre)
12     resumen.append({
13         "archivo": nombre,
14         "filas": len(tabla),
15         "columnas": tabla.shape[1],
16         "sample_id": tabla["sample_id"].nunique(),
17         "clases": tabla["class_name"].nunique(),
18         "duplicados": tabla.duplicated().sum(),
19         "nulos": tabla.isna().sum().sum(),
20     })
21
22 resumen_df = pd.DataFrame(resumen)
23 print(resumen_df)
```

9.2 Aspectos que deben revisarse

- tipos de datos y categorías;
- valores faltantes y duplicados;

- consistencia entre `class_id`, `class_name` y `macro_class`;
- valores extremos de bandas e índices;
- tamaños muy diferentes entre polígonos;
- desbalance de clases;
- variables constantes o casi constantes;
- correlaciones altas y redundancia;
- distribución por `split`;
- coherencia espacial y posibles observaciones anómalas;
- presencia de información que no debería entrar al modelo.

9.3 Variables que no deben usarse directamente como predictores

Para un primer modelo, deberían excluirse identificadores, etiquetas y textos:

```
1 columnas_no_predictoras = [  
2     "sample_id", "class_id", "class_name", "macro_class",  
3     "season", "confidence", "split", "source", "notes"  
4 ]
```

El uso de `x`, `y` y `scl` debe discutirse. Pueden aportar capacidad predictiva, pero también inducir dependencia espacial o codificar información asociada al proceso de selección. Se recomienda comparar modelos con y sin estas variables.

9.4 Tratamiento de valores atípicos

No debe eliminarse automáticamente una observación por estar lejos de la media. En datos ambientales, un valor extremo puede ser:

- un error de medición;
- un borde entre coberturas;
- una condición ambiental poco frecuente;
- una observación válida y científicamente relevante.

Toda eliminación debe quedar documentada con el criterio utilizado, el número de filas afectadas y el impacto sobre cada clase y `sample_id`.

Producto esperado del Práctico 2

Un notebook o informe reproducible que compare las versiones del dataset, identifique problemas de calidad, justifique las decisiones de curación y exporte una tabla final sin sobrescribir los archivos originales. Debe incluir un registro claro de transformaciones.

10 Práctico 3: aprendizaje automático

Fecha de entrega: 02/10/2026.

El equipo puede desarrollar aprendizaje supervisado, aprendizaje no supervisado o una combinación de ambos. La elección debe estar vinculada con una pregunta concreta y con los hallazgos de los prácticos anteriores.

10.1 Alternativa A: aprendizaje supervisado

El objetivo es predecir `class_name` a partir de bandas e índices. Se recomienda comenzar con un modelo base interpretable y luego comparar al menos dos algoritmos.

Modelos posibles:

- regresión logística multinomial;
- árbol de decisión;
- Random Forest;
- Extra Trees;
- HistGradientBoosting;
- máquinas de vectores de soporte.

```
1 from sklearn.ensemble import RandomForestClassifier
2 from sklearn.metrics import classification_report, confusion_matrix
3
4 features = [
5     "B04", "B03", "B02", "B05", "B06", "B07",
6     "B08", "B8A", "B11", "B12",
7     "NDVI", "NDWI", "MNDWI", "NDBI_like",
8     "SWIR_ratio", "NIR_SWIR_ratio", "RED_SWIR_ratio",
9     "GREEN_SWIR_ratio", "BLUE_RED_ratio"
10 ]
11
12 train = df[df["split"] == "train"]
13 valid = df[df["split"] == "validation"]
14 test = df[df["split"] == "test"]
15
16 modelo = RandomForestClassifier(
17     n_estimators=300,
18     class_weight="balanced",
19     random_state=42,
20     n_jobs=-1,
21 )
22
23 modelo.fit(train[features], train["class_name"])
24 pred_valid = modelo.predict(valid[features])
25
26 print(classification_report(valid["class_name"], pred_valid))
27 print(confusion_matrix(valid["class_name"], pred_valid))
```

10.2 Métricas recomendadas

- F1 macro;
- balanced accuracy;
- precisión y exhaustividad por clase;

- matriz de confusión;
- desempeño separado en validación y prueba;
- métricas por píxel y, cuando sea posible, resumen por `sample_id`.

La exactitud global no es suficiente cuando las clases están desbalanceadas.

10.3 Alternativa B: aprendizaje no supervisado

El objetivo es investigar si las observaciones forman agrupamientos naturales sin utilizar la etiqueta durante el ajuste.

Métodos posibles:

- K-Means;
- clustering jerárquico;
- DBSCAN o HDBSCAN;
- reducción de dimensionalidad mediante PCA;
- combinación de PCA y clustering.

```
1 from sklearn.pipeline import make_pipeline
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.decomposition import PCA
4 from sklearn.cluster import KMeans
5
6 pipeline = make_pipeline(
7     StandardScaler(),
8     PCA(n_components=0.95, random_state=42),
9     KMeans(n_clusters=3, random_state=42, n_init=20),
10 )
11
12 clusters = pipeline.fit_predict(df[features])
13 df_resultado = df.assign(cluster=clusters)
14
15 print(pd.crosstab(df_resultado["class_name"], df_resultado["cluster"]))
```

Cluster no equivale a clase

Los números de cluster son arbitrarios. Un agrupamiento puede dividir una clase en varios grupos o reunir observaciones de clases distintas. La comparación con las etiquetas debe realizarse después del ajuste y utilizarse como herramienta de interpretación.

10.4 Alternativa C: enfoque combinado

Un enfoque híbrido puede utilizar clustering y reducción de dimensionalidad para comprender la estructura del espacio de variables, detectar casos ambiguos y luego entrenar un clasificador supervisado.

Ejemplos:

- comparar clusters con etiquetas conocidas;
- detectar puntos alejados de los centroides;

- visualizar errores del clasificador en el espacio PCA;
- incorporar distancias a centroides como variables experimentales;
- estudiar si los errores se concentran en determinados `sample_id`.

Producto esperado del Práctico 3

Un experimento reproducible con pregunta, hipótesis, selección de datos, modelo o método, validación, métricas, interpretación, limitaciones y conclusiones. El conjunto de prueba debe reservarse para la evaluación final.

11 Prevención de fuga de información

La fuga de información ocurre cuando el modelo recibe, directa o indirectamente, datos que no debería conocer durante el entrenamiento.

11.1 Riesgos específicos de esta mentoría

- dividir filas del mismo `sample_id` entre entrenamiento y prueba;
- normalizar usando todo el dataset antes de separar los conjuntos;
- ajustar selección de variables con el conjunto de prueba;
- utilizar `class_id`, `class_name` o `macro_class` como predictores;
- tomar decisiones repetidas mirando el resultado del conjunto de prueba;
- balancear antes de preservar los splits y los grupos;
- incluir información textual de `notes` que describa explícitamente la clase.

11.2 Uso correcto de los splits

- **train**: ajuste de parámetros del modelo;
- **validation**: comparación de alternativas e hiperparámetros;
- **test**: evaluación final, utilizada una vez que el procedimiento está definido.

En el dataset actual, cada `sample_id` está contenido en un único split, lo que ayuda a preservar la independencia entre conjuntos.

12 Reproducibilidad y organización del trabajo

12.1 Estructura recomendada

```
1 mentoría-m10-equipo/  
2 |-- README.md  
3 |-- requirements.txt  
4 |-- data/  
5 |   |-- raw/  
6 |   |-- processed/
```

```

7 |-- notebooks/
8 |   |-- 01_analisis_visualizacion.ipynb
9 |   |-- 02_eda_curacion.ipynb
10 |   |-- 03_modelado.ipynb
11 |-- src/
12 |   |-- data.py
13 |   |-- features.py
14 |   |-- models.py
15 |-- reports/
16 |   |-- figures/
17 |-- models/
18 '-- video/

```

12.2 Buenas prácticas

- no modificar los CSV originales;
- usar rutas relativas y `pathlib`;
- fijar semillas aleatorias;
- registrar versiones de dependencias;
- separar código reutilizable del análisis narrativo;
- evitar notebooks con celdas ejecutadas fuera de orden;
- documentar decisiones y supuestos;
- usar Git y commits pequeños con mensajes descriptivos;
- verificar que el proyecto pueda ejecutarse desde cero.

13 Cronograma de la mentoría

Fecha	Actividad	Resultado esperado
07/08/2026	Práctico 1 de análisis y visualización	Comprensión inicial del dataset, estadísticas, gráficos e interpretación.
04/09/2026	Práctico 2 de análisis exploratorio y curación de datos	Diagnóstico de calidad, decisiones justificadas y dataset curado.
02/10/2026	Práctico 3 de aprendizaje supervisado, no supervisado o ambos	Experimento de modelado, validación, métricas e interpretación.
31/10/2026	Video de presentación final de mentoría	Síntesis audiovisual del problema, metodología, resultados y conclusiones.
04/12/2026 y 05/12/2026	Jornadas de presentación de mentorías	Presentación final del trabajo y respuesta a preguntas.

14 Video final y presentación en jornadas

14.1 Contenido recomendado para el video

1. presentación del problema y del equipo;
2. descripción de las tablas y variables utilizadas;
3. principales hallazgos del análisis exploratorio;
4. decisiones de curación;
5. metodología de modelado;
6. métricas y visualizaciones principales;
7. limitaciones;
8. conclusiones y posibles líneas futuras.

14.2 Criterios de comunicación

- evitar leer código en pantalla;
- explicar primero la pregunta y luego la técnica;
- mostrar gráficos legibles y con títulos;
- diferenciar claramente datos, resultados e interpretaciones;
- no ocultar errores, limitaciones o clases difíciles;
- atribuir el origen del dataset y las herramientas utilizadas;
- asegurar que todos los integrantes comprendan el flujo completo.

15 Checklist general

- | | |
|--|--|
| ☐ Identificamos la unidad de análisis. | ☐ Evitamos fuga de información. |
| ☐ Comprendemos el papel de <code>sample_id</code> . | ☐ Conservamos los datos originales. |
| ☐ Revisamos tipos y categorías. | ☐ Documentamos cada transformación. |
| ☐ Comparamos las cinco tablas. | ☐ Usamos métricas por clase. |
| ☐ Analizamos clases por fila y polígono. | ☐ Incluimos una línea base. |
| ☐ Verificamos nulos y duplicados. | ☐ Registramos semillas y versiones. |
| ☐ Estudiamos valores atípicos. | ☐ Interpretamos cada visualización. |
| ☐ Revisamos correlaciones. | ☐ Declaramos limitaciones. |
| ☐ Respetamos los splits provistos. | ☐ El notebook ejecuta desde cero. |

16 Glosario breve

Bandas espectrales

Mediciones de reflectancia en distintas regiones del espectro electromagnético.

Clase

Categoría de cobertura terrestre que se desea explicar o predecir.

Curación

Proceso documentado de revisión, corrección, filtrado y preparación de datos.

Dataset balanceado

Conjunto en el que las clases tienen igual o similar cantidad de observaciones.

GeoJSON

Formato vectorial basado en JSON utilizado, en la etapa previa, para almacenar polígonos etiquetados.

Índice espectral

Combinación matemática de bandas diseñada para resaltar determinadas propiedades.

Píxel

Unidad espacial elemental de la imagen original y unidad representada por cada fila.

Polígono de referencia

Región etiquetada de la que se extrajo un conjunto de píxeles.

sample_id

Identificador que vincula cada fila con su polígono de origen.

Split

Partición del dataset destinada a entrenamiento, validación o prueba.

17 Recursos

- Repositorio general: https://github.com/pablonicolasr/mentodatos_pdis
- Tablas de trabajo: https://github.com/pablonicolasr/mentodatos_pdis/tree/main/tables
- Documentación de pandas: <https://pandas.pydata.org/docs/>
- Documentación de scikit-learn: <https://scikit-learn.org/stable/>
- Documentación de Matplotlib: <https://matplotlib.org/stable/>

Mensaje final

El desafío principal no consiste en aplicar la mayor cantidad de algoritmos, sino en comprender cómo fue construido el dataset, formular preguntas relevantes, evitar errores metodológicos y justificar cada decisión a partir de evidencia.