

Mentoría M10

Práctico 2

Análisis Exploratorio y Curación de Datos

Clasificación de la Cobertura Terrestre

Fecha de entrega: 04/09

Análisis de calidad, consistencia, utilidad, enriquecimiento y preparación de datos para etapas posteriores de aprendizaje automático.

Índice

1. Descripción general	3
2. Objetivos	3
3. Dominio del problema	3
4. Consigna general	3
5. Parte I — Auditoría inicial del dataset	4
6. Parte II — Valores faltantes	4
7. Parte III — Duplicados y consistencia	4
8. Parte IV — Curación de variables categóricas	4
9. Parte V — Análisis estadístico de variables numéricas	5
10. Parte VI — Detección de valores atípicos	5
10.1. Método IQR	5
10.2. Z-score	5
10.3. MAD robusto	5
10.4. Método multivariado opcional	6
11. Parte VII — Distribución y balance de clases	6
12. Parte VIII — Comparación estadística entre clases	6
12.1. ANOVA	6
12.2. Kruskal–Wallis	6
12.3. Variables categóricas	6
13. Parte IX — Correlación y redundancia	7
14. Parte X — Relevancia de variables	7
15. Parte XI — Ingeniería de variables espectrales	7
15.1. NDVI	7
15.2. NDWI	7
15.3. MNDWI	7
15.4. BSI	7
16. Parte XII — Ingeniería de variables geoespaciales	8
17. Parte XIII — Validación geoespacial	8
18. Parte XIV — Normalización y transformación	8
18.1. StandardScaler	8
18.2. MinMaxScaler	8
18.3. RobustScaler	8
19. Parte XV — Pipeline reproducible de curación	8
20. Parte XVI — Persistencia y trazabilidad	9

21. Parte XVII — Preparación para Machine Learning	9
21.1. Prevención de fuga de información	9
22. Parte XVIII — Control de calidad final	9
23. Entregables	9
24. Estructura mínima recomendada del Notebook	10
25. Criterios de evaluación	10
26. Preguntas guía	11
27. Resultado esperado	11

1. Descripción general

En esta segunda etapa se profundizará el análisis exploratorio del dataset utilizado para el problema de **clasificación de la cobertura terrestre**. El objetivo será evaluar de manera sistemática la **calidad, consistencia, representatividad y utilidad** de los datos antes de aplicar técnicas de aprendizaje automático.

El trabajo deberá identificar problemas de calidad, justificar decisiones de limpieza, documentar las transformaciones realizadas y generar un conjunto de datos final **depurado, trazable, reproducible y preparado para modelado**.

El propósito del práctico no es únicamente “limpiar datos”, sino demostrar que cada decisión de curación puede justificarse desde el punto de vista estadístico, geoespacial y del problema de clasificación.

2. Objetivos

Al finalizar el práctico, cada grupo deberá ser capaz de:

- caracterizar estadísticamente el dataset;
- identificar valores faltantes, duplicados y registros inconsistentes;
- detectar errores en variables numéricas, categóricas y geoespaciales;
- analizar posibles valores atípicos utilizando métodos estadísticos robustos;
- evaluar la distribución y el balance de las clases de cobertura;
- detectar variables redundantes, poco informativas o potencialmente problemáticas;
- justificar transformaciones y estrategias de normalización;
- validar geometrías y sistemas de referencia espacial;
- generar nuevas variables a partir de la información espectral y geoespacial;
- construir un flujo reproducible de análisis y curación;
- generar un dataset final apto para una posterior etapa de Machine Learning.

3. Dominio del problema

El dominio de aplicación será la **clasificación de cobertura terrestre** a partir de información espectral, tabular y/o geoespacial.

Dependiendo del dataset disponible, las clases pueden incluir, entre otras: salina o superficie evaporítica, suelo desnudo, suelo rocoso, agua o humedad, vegetación y otras coberturas definidas por cada equipo.

El análisis deberá considerar que diferentes coberturas pueden presentar distribuciones estadísticas distintas y firmas espectrales parcialmente superpuestas.

4. Consigna general

Cada grupo deberá construir un **Notebook reproducible** que tome el dataset original como entrada y produzca:

1. un diagnóstico de calidad;

2. un análisis estadístico exploratorio;
3. una estrategia de curación;
4. un conjunto de variables enriquecidas;
5. un dataset final depurado;
6. un reporte de las decisiones adoptadas.

Todas las decisiones deberán estar justificadas. No se considerará suficiente aplicar funciones de limpieza sin explicar el criterio utilizado.

5. Parte I — Auditoría inicial del dataset

Informar como mínimo: cantidad de filas y columnas, nombres de variables, tipos de datos, cantidad de valores únicos, memoria utilizada, variable objetivo, identificadores, variables espectrales, variables geográficas, variables categóricas y variables derivadas.

Construir una tabla resumen:

Variable	Tipo conceptual	Tipo	Nulos	Únicos	Uso esperado
B08	Banda espectral	numérica	–	–	Predictora
class_name	Etiqueta	categórica	–	–	Objetivo
x	Coordenada	numérica	–	–	Espacial

6. Parte II — Valores faltantes

Para cada variable calcular:

$$\text{MissingRate}_j = \frac{\text{valores faltantes en } X_j}{n}$$

Reportar cantidad absoluta, porcentaje, patrón de ausencia, posibles causas y estrategia propuesta.

Discutir, cuando corresponda, si el mecanismo parece compatible con MCAR, MAR o MNAR.

No se debe imputar automáticamente. Si una variable no posee valores faltantes, la estrategia correcta puede ser simplemente documentar que no requiere tratamiento.

7. Parte III — Duplicados y consistencia

Analizar filas completamente duplicadas, duplicados según identificadores, registros repetidos por coordenadas, posibles duplicados por combinación de geometría/clase/fecha y registros con misma entidad pero atributos contradictorios.

Distinguir entre duplicado real, repetición válida, múltiples píxeles de una misma unidad espacial y observaciones temporales diferentes.

8. Parte IV — Curación de variables categóricas

Para cada variable categórica:

1. listar categorías;
2. calcular frecuencias absolutas y relativas;

3. detectar diferencias por mayúsculas/minúsculas;
4. detectar espacios, abreviaturas y errores tipográficos;
5. revisar categorías semánticamente equivalentes;
6. estandarizar nombres.

Ejemplo:

```
df["class_name"] = (
    df["class_name"]
    .str.strip()
    .str.lower()
    .str.replace(" ", "_")
)
```

9. Parte V — Análisis estadístico de variables numéricas

Para las variables numéricas calcular, como mínimo:

$$\bar{x}, \quad \tilde{x}, \quad s, \quad Q_1, \quad Q_3, \quad IQR, \quad \min(x), \quad \max(x)$$

con:

$$IQR = Q_3 - Q_1$$

Incluir asimetría, curtosis, histogramas, boxplots, violin plots cuando aporten información y ECDF para variables relevantes.

El análisis deberá realizarse globalmente y, cuando corresponda, **por clase de cobertura**.

10. Parte VI — Detección de valores atípicos

Aplicar y comparar al menos **dos estrategias**.

10.1. Método IQR

$$x < Q_1 - 1.5 IQR \quad \text{o} \quad x > Q_3 + 1.5 IQR$$

10.2. Z-score

$$z_i = \frac{x_i - \bar{x}}{s}$$

Puede utilizarse como criterio exploratorio $|z_i| > 3$.

10.3. MAD robusto

$$MAD = \text{mediana}(|x_i - \tilde{x}|)$$

$$z_i^* = 0.6745 \frac{x_i - \tilde{x}}{MAD}$$

10.4. Método multivariado opcional

Explorar Isolation Forest, Local Outlier Factor o distancia de Mahalanobis.

Un valor atípico estadístico no es necesariamente un error. En teledetección, un valor extremo puede corresponder a una cobertura minoritaria pero físicamente válida. No se deberán eliminar outliers sin análisis previo.

11. Parte VII — Distribución y balance de clases

Analizar cantidad de observaciones por clase, proporción relativa, distribución espacial, cantidad de polígonos o unidades independientes y clases minoritarias.

$$p_k = \frac{n_k}{n}$$

Opcionalmente evaluar entropía:

$$H = - \sum_k p_k \log(p_k)$$

o una prueba χ^2 respecto de una distribución de referencia.

En datasets formados por píxeles, el balance por cantidad de píxeles puede ser engañoso. Se recomienda analizar también el balance por polígonos, regiones o unidades espaciales independientes.

12. Parte VIII — Comparación estadística entre clases

Seleccionar variables relevantes y estudiar si sus distribuciones difieren entre clases.

12.1. ANOVA

Cuando los supuestos sean razonables:

$$F = \frac{\text{variabilidad entre grupos}}{\text{variabilidad dentro de los grupos}}$$

Reportar estadístico F , p -valor y tamaño del efecto.

Puede utilizarse:

$$\eta^2 = \frac{SS_{\text{entre}}}{SS_{\text{total}}}$$

12.2. Kruskal–Wallis

Cuando no resulte apropiado asumir normalidad:

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(N+1)$$

Interpretar el p -valor y complementar con tamaño de efecto.

12.3. Variables categóricas

Cuando corresponda utilizar prueba χ^2 y V de Cramér.

13. Parte IX — Correlación y redundancia

Calcular matrices de correlación Pearson y Spearman. Detectar variables altamente redundantes y discutir bandas espectrales fuertemente correlacionadas, índices derivados de las mismas bandas, riesgo de multicolinealidad y posibilidad de selección de variables.

Opcionalmente calcular:

$$VIF_j = \frac{1}{1 - R_j^2}$$

14. Parte X — Relevancia de variables

Evaluar qué variables aportan información para separar clases utilizando al menos dos enfoques entre: ANOVA/Kruskal–Wallis, tamaño del efecto, información mutua, F-score, separación entre distribuciones, importancia de un modelo simple y permutation importance.

Identificar variables claramente útiles, redundantes, sospechosas y potencialmente descartables.

15. Parte XI — Ingeniería de variables espectrales

Cuando existan bandas Sentinel-2 u otras variables espectrales, evaluar índices derivados.

15.1. NDVI

$$NDVI = \frac{NIR - RED}{NIR + RED}$$

15.2. NDWI

$$NDWI = \frac{GREEN - NIR}{GREEN + NIR}$$

15.3. MNDWI

$$MNDWI = \frac{GREEN - SWIR}{GREEN + SWIR}$$

15.4. BSI

$$BSI = \frac{(SWIR + RED) - (NIR + BLUE)}{(SWIR + RED) + (NIR + BLUE)}$$

También podrán explorarse:

$$\frac{SWIR1}{SWIR2}, \quad \frac{NIR}{SWIR1}, \quad \frac{RED}{SWIR1}, \quad \frac{GREEN}{SWIR1}$$

Cada variable nueva deberá acompañarse de fórmula, interpretación, justificación física, análisis estadístico y evaluación de utilidad.

16. Parte XII — Ingeniería de variables geoespaciales

Si se dispone de geometrías, calcular cuando sea pertinente: área, perímetro, centroide, relación área/perímetro, compacidad, distancia a elementos relevantes, pertenencia a regiones, relaciones espaciales, vecinos y densidades locales.

Una posible medida de compacidad es:

$$C = \frac{4\pi A}{P^2}$$

17. Parte XIII — Validación geoespacial

Verificar CRS, geometrías vacías, nulas e inválidas, self-intersections, coordenadas fuera del rango esperado, duplicación de geometrías y consistencia entre CRS y unidades.

El cálculo de áreas y perímetros no debe realizarse directamente en un CRS geográfico medido en grados. Se deberá utilizar un CRS proyectado apropiado para el área de estudio.

18. Parte XIV — Normalización y transformación

Evaluar si las variables requieren transformación antes del modelado.

18.1. StandardScaler

$$z = \frac{x - \mu}{\sigma}$$

18.2. MinMaxScaler

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

18.3. RobustScaler

Basado en mediana e IQR.

No es obligatorio normalizar en esta etapa si el algoritmo futuro no lo requiere, pero sí se deberá dejar preparada una estrategia reproducible.

19. Parte XV — Pipeline reproducible de curación

El notebook deberá organizar las transformaciones como una secuencia clara:

RAW → VALIDACIÓN → CURACIÓN → FEATURE ENGINEERING → DATASET FINAL

Se recomienda separar conceptualmente carga, validación, limpieza, transformación, enriquecimiento, control de calidad y exportación.

Ejemplo:

```
def curate_dataset(df):
    df = normalize_columns(df)
    df = validate_categories(df)
    df = remove_invalid_records(df)
    df = generate_spectral_features(df)
    df = generate_spatial_features(df)
    return df
```

Todas las funciones deberán recibir entradas explícitas, devolver resultados explícitos, evitar modificaciones silenciosas y ser reutilizables.

20. Parte XVI — Persistencia y trazabilidad

Se recomienda mantener al menos dos versiones: **raw** y **curated**.

Opcionalmente construir un ETL utilizando SQLite y SQLAlchemy:

Extract → Transform → Load

El flujo puede almacenar datos originales, datos curados, métricas de calidad, fecha de ejecución, cantidad de registros y reglas aplicadas.

21. Parte XVII — Preparación para Machine Learning

Definir explícitamente variable objetivo, predictoras, identificadores, variables excluidas, variables derivadas, estrategia de codificación y estrategia de escalado.

21.1. Prevención de fuga de información

Si múltiples píxeles provienen del mismo polígono o unidad espacial, el particionado deberá realizarse por grupo:

grupo completo $\in \{\text{train}, \text{test}\}$

y no por píxel individual.

22. Parte XVIII — Control de calidad final

Construir una tabla comparativa:

Indicador	Dataset original	Dataset curado
Filas	—	—
Columnas	—	—
Valores faltantes	—	—
Duplicados	—	—
Geometrías inválidas	—	—
Categorías inconsistentes	—	—
Variables predictoras	—	—

El grupo deberá explicar por qué el dataset final es de mayor calidad y qué problemas permanecen abiertos.

23. Entregables

Cada grupo deberá entregar:

1. **Notebook** ejecutable de principio a fin.
2. **Dataset curado** en CSV, Parquet, GeoPackage u otro formato apropiado.
3. **Diccionario de datos**.
4. **Reporte de calidad** antes y después de la curación.
5. **Listado de transformaciones** realizadas.
6. **Conclusiones** sobre la utilidad del dataset para Machine Learning.

24. Estructura mínima recomendada del Notebook

1. Introducción.
2. Importación de librerías.
3. Configuración.
4. Carga.
5. Auditoría.
6. Valores faltantes.
7. Duplicados.
8. Variables categóricas.
9. Análisis estadístico.
10. Outliers.
11. Balance de clases.
12. Comparación entre clases.
13. Correlación.
14. Selección preliminar de variables.
15. Feature engineering espectral.
16. Feature engineering geoespacial.
17. Validación geométrica.
18. Curación.
19. Pipeline reproducible.
20. Dataset final.
21. Reporte comparativo.
22. Conclusiones.

25. Criterios de evaluación

Criterio	Peso
Auditoría y comprensión del dataset	10 %
Tratamiento de faltantes, duplicados e inconsistencias	15 %
Análisis estadístico	20 %
Curación geoespacial	10 %
Ingeniería y evaluación de variables	15 %
Pipeline reproducible	15 %
Preparación para Machine Learning	10 %
Documentación, interpretación y conclusiones	5 %
Total	100 %

26. Preguntas guía

El informe y el Notebook deberán permitir responder:

1. ¿El dataset posee calidad suficiente para ser modelado?
2. ¿Qué problemas fueron encontrados?
3. ¿Cuáles fueron corregidos y cuáles permanecen?
4. ¿Existen clases desbalanceadas?
5. ¿Las observaciones pueden considerarse independientes?
6. ¿Qué variables presentan mayor capacidad discriminante?
7. ¿Qué variables son redundantes?
8. ¿Qué nuevas variables fueron generadas?
9. ¿Las nuevas variables aportan realmente información?
10. ¿Existen anomalías estadísticamente extremas pero físicamente válidas?
11. ¿Las geometrías son válidas y se encuentran en el CRS correcto?
12. ¿El particionado futuro puede sufrir fuga de información?
13. ¿El pipeline permite reproducir exactamente el dataset final?

27. Resultado esperado

Al finalizar el práctico se espera obtener un conjunto de datos limpio, consistente, documentado, estadísticamente caracterizado, geoespacialmente validado, enriquecido mediante nuevas variables, trazable, reproducible y preparado para técnicas de aprendizaje automático.

El objetivo final es poder afirmar, con evidencia estadística y criterios de calidad, que el dataset resultante constituye una base confiable para construir modelos de clasificación de cobertura terrestre.