

Práctico 3 – Aprendizaje supervisado y no supervisado

Reconocimiento de patrones ambientales en sistemas salares

Proyecto: SalarIA

Entrega: 02/10/2026

Continuidad del proyecto

El Práctico 3 toma como entrada el trabajo realizado previamente: el TP1 se concentró en análisis exploratorio, visualización, bandas e índices espectrales; el TP2 formalizó la curación, la trazabilidad del pipeline y la preparación de un conjunto de datos apto para Machine Learning. En esta etapa se construirán y compararán modelos iniciales de aprendizaje automático orientados al reconocimiento de coberturas y subambientes salares.

Objetivo general

Desarrollar una primera metodología reproducible para el reconocimiento de patrones ambientales en el sistema salar mediante técnicas de **aprendizaje supervisado y no supervisado**, evaluando su desempeño, interpretando sus resultados y analizando su correspondencia con las categorías ambientales disponibles.

Objetivos específicos

Al finalizar el práctico, cada grupo deberá ser capaz de:

- construir una partición experimental evitando fuga de información entre observaciones pertenecientes al mismo `sample_id`;
- establecer un modelo *baseline* como punto de comparación;
- entrenar y comparar al menos dos clasificadores supervisados;
- evaluar los modelos mediante F1-macro, balanced accuracy, matriz de confusión y métricas por clase;
- aplicar clustering para identificar agrupamientos naturales entre observaciones espectralmente similares;
- seleccionar y justificar la cantidad de clusters mediante una métrica interna;
- comparar de manera interpretativa los clusters con las categorías ambientales preexistentes;
- relacionar resultados con bandas, índices, distribución espacial y conocimiento del dominio;
- documentar limitaciones y proponer el siguiente experimento del proyecto.

Datos de trabajo

Se deberá utilizar preferentemente el dataset curado producido en el TP2, por ejemplo `olaroz_samples_curated_practico2.csv`. El notebook entregado admite como fallback una tabla de features del repositorio, pero el grupo deberá indicar explícitamente si utilizó dicho fallback y explicar la diferencia respecto del producto curado.

Las variables objetivo disponibles corresponden a categorías ambientales tales como `salina`, `suelo_desnudo`, `agua_humedad` y `suelo_rocoso`. Los predictores deberán provenir principalmente de bandas Sentinel-2 e índices espectrales disponibles.

Reglas metodológicas obligatorias

1. **Evitar fuga de información.** No utilizar como predictores `class_id`, `class_name`, `macro_class`, `sample_id`, `split`, `source`, `notes`, campos de linaje u otras columnas que codifiquen directa o indirectamente la respuesta.
2. **Separación por grupos.** El conjunto train/test debe construirse respetando `sample_id` completos. No se acepta una separación aleatoria simple fila a fila.
3. **Baseline.** Antes de evaluar modelos más complejos debe entrenarse un clasificador ingenuo, por ejemplo `DummyClassifier`.
4. **Preprocesamiento reproducible.** Imputación, escalado y modelo deben integrarse en `Pipeline` siempre que corresponda.
5. **Test final.** El conjunto de test no debe utilizarse para seleccionar hiperparámetros.
6. **Clustering sin etiquetas.** La etiqueta ambiental no puede utilizarse para ajustar K-Means. Solo podrá usarse después para interpretar el resultado.

Parte A – Aprendizaje supervisado

Cada grupo deberá:

1. construir X , y y los grupos geográficos;
2. crear una separación train/test aproximada 80/20 mediante `GroupShuffleSplit`;
3. verificar programáticamente que existen cero `sample_id` compartidos entre ambas particiones;
4. entrenar un *baseline*;
5. entrenar como mínimo:
 - Regresión Logística multiclase con imputación y estandarización;
 - Random Forest con configuración reproducible y tratamiento del desbalance.
6. comparar los modelos mediante **F1-macro** como métrica principal y **balanced accuracy** como métrica complementaria;
7. seleccionar un modelo para análisis detallado;
8. presentar `classification_report` y matriz de confusión normalizada;
9. identificar clases fáciles, clases problemáticas y confusiones relevantes;
10. calcular una interpretación mínima de variables mediante importancia por permutación u otro método justificado.

Pregunta central del enfoque supervisado

¿Hasta qué punto la señal espectral disponible permite predecir las categorías ambientales existentes cuando la evaluación respeta la estructura de grupos geográficos?

Parte B – Aprendizaje no supervisado

Se deberá aplicar un enfoque de clustering sobre las mismas variables predictoras, sin utilizar etiquetas durante el ajuste.

Cada grupo deberá:

1. imputar y estandarizar las variables;
2. entrenar **KMeans** para diferentes valores de k , inicialmente entre 2 y 6;
3. calcular *silhouette score* para cada configuración;
4. elegir y justificar un valor final de k . No es obligatorio usar $k = 4$ únicamente porque existan cuatro clases conocidas;
5. ajustar el clustering final;
6. comparar externamente clusters y clases mediante tabla cruzada y, como apoyo, ARI y NMI;
7. proyectar los datos con PCA 2D para visualizar la estructura de agrupamiento;
8. visualizar la distribución espacial de clusters utilizando las coordenadas disponibles;
9. discutir si los agrupamientos reproducen, complementan o cuestionan las categorías ambientales existentes.

Pregunta central del enfoque no supervisado

¿Los datos revelan agrupamientos espectrales naturales compatibles con las clases existentes, o muestran gradientes/subestructuras ambientales que la clasificación previa no representa completamente?

Parte C – Comparación e interpretación

La entrega deberá incluir una discusión conjunta de ambos enfoques. No se deben comparar directamente métricas que responden a objetivos diferentes. En particular, F1-macro evalúa clasificación supervisada, mientras que *silhouette* mide cohesión/separación interna de clusters. ARI y NMI se utilizarán solamente para estudiar correspondencia entre particiones.

El análisis deberá responder:

- ¿Qué modelo supervisado supera con mayor claridad al baseline?
- ¿Qué clases presentan mayor dificultad y por qué podría ocurrir?
- ¿Qué variables aportan señal discriminante?
- ¿Qué valor de k resulta razonable según los datos?
- ¿Qué relación existe entre clusters y categorías ambientales?
- ¿Existen patrones espaciales coherentes?
- ¿Qué limitaciones impiden generalizar todavía los resultados a otros salares o períodos temporales?

Notebook guiado

Se entrega un notebook base de estilo Coursera. Las partes obligatorias a completar están delimitadas por:

```
### START CODE HERE ###  
# codigo del estudiante  
### END CODE HERE ###
```

El notebook contiene pruebas simples mediante **assert**. No deben eliminarse. El grupo puede agregar celdas, funciones, modelos o visualizaciones adicionales siempre que el flujo obligatorio continúe ejecutando de punta a punta.

Extensiones opcionales

Se valorarán extensiones técnicamente justificadas, entre ellas:

- validación cruzada agrupada;
- ajuste de hiperparámetros únicamente dentro del conjunto de entrenamiento;
- comparación entre bandas solas y bandas + índices;
- clustering alternativo (jerárquico, DBSCAN/HDBSCAN);
- estabilidad del clustering frente a semillas o submuestras;
- mapas de errores y exportación para QGIS;
- centroides/perfiles espectrales por cluster;
- diseño de una partición geográfica más estricta para evaluar generalización espacial.

Entregables

1. M10_Practico3_Aprendizaje_ML_GRUPO_N.ipynb, ejecutado en orden, sin errores y con todas las respuestas.
2. predicciones_tp3_grupo_N.csv, incluyendo como mínimo `sample_id`, clase real, predicción supervisada y cluster asignado.
3. Informe técnico breve en PDF de hasta 4 páginas, o exportación equivalente de la sección final del notebook, según indique la cátedra.

Criterios de evaluación

Criterio	Peso
Correcta partición experimental y control de fuga	15 %
Baseline, pipelines y calidad del código	15 %
Evaluación del aprendizaje supervisado	20 %
Aplicación y evaluación del clustering	20 %
Interpretación ambiental, visualizaciones y análisis de errores	20 %
Reproducibilidad, conclusiones y presentación	10 %
Total	100 %

Criterio de aprobación técnica

Una entrega correcta no consiste únicamente en obtener métricas altas. Debe demostrar que el grupo comprende **qué información aprende cada modelo, cómo se evaluó, qué errores comete, qué estructura revelan los datos y hasta dónde pueden sostenerse las conclusiones**. La reproducibilidad y la ausencia de fuga de información son requisitos fundamentales.