

TP3 Parte 2: metodología completa de ML para salares

Aprendizaje no supervisado + supervisado + diseño experimental espacial

Sentinel-2 L2A - Olaroz, Cauchari y Hombre Muerto

22 de septiembre de 2026

1. Idea general del TP3 Parte 2

Propósito

Construir una metodología completa para clasificar coberturas en salares usando productos Sentinel-2 y Machine Learning.

- No empezar directamente con un clasificador.
- Primero explorar estructura espectral con aprendizaje no supervisado.
- Después entrenar modelos supervisados con etiquetas depuradas.
- Evaluar con splits espaciales y transferencia entre salares.

2. Pregunta científica

Pregunta central

¿Los patrones espectrales aprendidos en un salar permiten clasificar coberturas en otro salar?

- Olaroz: dominio base.
- Cauchari: transferencia cercana.
- Hombre Muerto: validación externa.
- Interesa tanto la métrica como el mapa de errores.

3. Entradas mínimas

- Raster de bandas Sentinel-2 L2A.
- Raster de features: bandas + índices.
- QA: fechas válidas y fracción válida.
- Metadatos de adquisición.

Variables

B02, B03, B04, B05, B06, B07, B08,
B8A, B11, B12, NDVI, NDWI, MNDWI,
NDMI, BSI.

4. Salida esperada

- Mapa de clusters no supervisados.
- Perfil espectral de clusters.
- Etiquetas depuradas para clases finales.
- Modelos supervisados entrenados.
- Métricas por clase y por experimento.
- Mapa de clases y mapa de confianza.
- Discusión de transferencia y errores.

5. Flujo completo del trabajo

Etapa	Producto
QA y EDA	Datos válidos y rangos plausibles
No supervisado	Clusters y zonas ambiguas
Etiquetado	Muestras limpias por clase
Supervisado	Modelo predictivo
Evaluación	Métricas, errores e incertidumbre
Transferencia	Generalización entre salares

6. Por qué no basta un split aleatorio

Problema

Los píxeles vecinos están espacialmente autocorrelacionados.

- Un split aleatorio mezcla píxeles casi idénticos en train y test.
- Las métricas pueden ser demasiado optimistas.
- La pregunta fuerte es: ¿generaliza a sectores no vistos?
- Por eso se usa split por bloques, polígonos o salares completos.

7. QA antes de entrenar

- Revisar `valid_fraction` por píxel.
- Excluir píxeles con NaN o baja cobertura temporal.
- Revisar rangos de reflectancia.
- Verificar índices: NDVI, NDWI, MNDWI, NDMI, BSI.
- Revisar RGB, falso color y mapas de humedad.

Regla

No hay buen modelo si los píxeles de entrada no son confiables.

8. Matriz de features

Cada píxel válido se convierte en un vector:

$$\mathbf{x}_i = [\text{bandas}, \text{índices}, \text{QA opcional}]$$

- Filas: píxeles o muestras.
- Columnas: variables predictoras.
- Etiqueta: sólo para aprendizaje supervisado.
- Coordenadas: necesarias para split espacial y mapas.

9. Bloque no supervisado

Objetivo

Descubrir estructura espectral antes de imponer etiquetas humanas.

- Detectar grupos naturales.
- Identificar zonas puras y zonas ambiguas.
- Ayudar a seleccionar muestras de entrenamiento.
- Ver si las clases esperadas se separan espectralmente.

10. K-Means como línea base

- Estandarizar variables antes de entrenar.
- Probar varios valores de k .
- Mapear los clusters al raster.
- Interpretar cada cluster con perfiles espectrales.
- No confundir cluster con clase final.

Mensaje clave

K-Means produce grupos matemáticos; la clase cartográfica requiere interpretación.

11. Elegir el número de clusters

Criterio	Uso
Inercia	Buscar codo
Silhouette	Separación y cohesión
Davies-Bouldin	Menor es mejor
Estabilidad	Repetir semillas y muestras
Interpretabilidad	Sentido espectral y espacial

12. Otros métodos no supervisados

- MiniBatch K-Means: eficiente con muchos píxeles.
- Gaussian Mixture Models: clusters probabilísticos.
- Agglomerative clustering: jerarquías en muestras pequeñas.
- DBSCAN/HDBSCAN: ruido y formas no compactas.
- PCA/UMAP: visualización del espacio espectral.

13. Perfilado de clusters

Para cada cluster reportar:

- Porcentaje de área.
- Media y dispersión de bandas e índices.
- Ubicación espacial.
- Interpretación tentativa.
- Relación con clases finales.

Ejemplo

Cluster 2: alta reflectancia, bajo NDVI, alto BSI - posible salina seca.

14. De clusters a etiquetas

- Un cluster puede ser una clase.
- Varios clusters pueden representar una misma clase.
- Un cluster puede mezclar clases y requerir revisión.
- Los clusters ambiguos no deben usarse como etiquetas automáticas.

Uso correcto

Usar clusters para asistir el etiquetado, no para reemplazar la validación.

15. Clases objetivo

- Salina.
- Suelo desnudo.
- Agua/humedad.
- Suelo rocoso.

Cuidado

Las clases son categorías operativas del TP, no límites geológicos oficiales.

16. Etiquetado supervisado

- Dibujar polígonos o puntos en QGIS.
- Evitar bordes y zonas dudosas.
- Asignar clase y confianza.
- Balancear clases minoritarias.
- Separar train/test por bloques o polígonos completos.

17. Modelos supervisados mínimos

Modelo	Rol
Random Forest	Línea base fuerte
Extra Trees	Mayor aleatoriedad
HistGradientBoosting	No lineal potente
SVM RBF	Comparación con escalado

18. Diseño experimental A

Intra-Olaroz

Evaluar generalización dentro del dominio base.

Train	Sectores A + B + C
Test	Sector D

- Separar espacialmente los bloques.
- Repetir si es posible con distintos sectores de test.

19. Diseño experimental B

Transferencia cercana

Entrenar en Olaroz y probar en Cauchari.

Train	Olaroz
Test	Cauchari

- Controlar superposición espacial.
- Analizar si el error crece respecto del intra-salar.

20. Diseño experimental C

Transferencia externa

Entrenar con Olaroz + Cauchari y probar en Hombre Muerto.

Train	Olaroz + Cauchari
Test	Hombre Muerto

- Es el experimento más exigente.
- Mide cambio de dominio.

21. Diseño experimental D

Leave-One-Salar-Out

Cada salar funciona una vez como dominio no visto.

Fold	Train	Test
1	Cauchari + Hombre Muerto	Olaroz
2	Olaroz + Hombre Muerto	Cauchari
3	Olaroz + Cauchari	Hombre Muerto

22. Métricas obligatorias

- F1 macro.
- Precision por clase.
- Recall por clase.
- Balanced accuracy.
- Matriz de confusión.
- Cohen's kappa como métrica complementaria.

Prioridad

Mirar métricas por clase, no sólo accuracy global.

23. Incertidumbre

- Generar mapa de probabilidad máxima.
- Detectar píxeles de baja confianza.
- Revisar si coinciden con bordes o transiciones.
- Usar baja confianza para aprendizaje activo.

$$\text{confianza}_i = \max_c P(y = c \mid \mathbf{x}_i)$$

24. Análisis de errores

- ¿Dónde se equivoca el modelo?
- ¿Qué clases se confunden?
- ¿El error aumenta al transferir a otro salar?
- ¿Los errores coinciden con clusters ambiguos?
- ¿Qué variables explican las confusiones?

25. Ablaciones

- Sólo bandas vs bandas + índices.
- Con y sin red edge.
- Con y sin SWIR.
- Umbral QA flexible vs estricto.
- Etiquetas manuales vs etiquetas asistidas por clusters.
- Un salar vs varios salares en entrenamiento.

26. Estructura del notebook

- 1 Carga de rasters y QA.
- 2 EDA y matriz de features.
- 3 No supervisado y mapa de clusters.
- 4 Perfilado e interpretación.
- 5 Etiquetas y split espacial.
- 6 Modelos supervisados.
- 7 Métricas y mapas.
- 8 Discusión y exportación.

27. Figuras mínimas

- RGB o falso color por salar.
- Índice de humedad: MNDWI o NDMI.
- Mapa K-Means.
- Perfil medio de clusters.
- Mapa supervisado de clases.
- Matriz de confusión.
- Mapa de confianza.

28. Tablas mínimas

- Fechas y calidad QA por salar.
- Cantidad de muestras por clase.
- Métricas por modelo.
- Métricas por experimento.
- Ablaciones.
- Importancia de variables.
- Resumen de errores principales.

29. Errores frecuentes

- Usar split aleatorio de píxeles.
- No aplicar no supervisado.
- Elegir k sin justificación.
- Confundir cluster con clase final.
- No escalar K-Means o SVM.
- Reportar sólo accuracy global.
- No revisar mapas visualmente.

30. Checklist final

- 1 QA revisado.
- 2 K-Means aplicado e interpretado.
- 3 Etiquetas depuradas.
- 4 Split espacial aplicado.
- 5 Modelos comparados.
- 6 Métricas por clase reportadas.
- 7 Mapas finales generados.
- 8 Transferencia entre salares discutida.

31. Cierre

Mensaje final

El TP3 Parte 2 no es sólo entrenar un modelo: es construir una evidencia completa de clasificación geoespacial.

- Explorar antes de etiquetar.
- Etiquetar antes de entrenar.
- Separar espacialmente antes de medir.
- Medir antes de concluir.